


# 개인정리-VAE

2024년 10월 31일 목요일 오후 1:49

## 1. 가능도(Likelihood)

- 확률 : 주어진 확률분포에서 관측값이 분포 안에서 얼마의 확률로 존재하는 가
- 확률 =  $p(\text{관측값 } x \mid \text{확률분포 } D)$
- 확률은 확률분포가 주어졌을 때 관측값  $x$ 에 대한 확률을 구하는 것

- 가능도 : 어떤 관측값이 어떤 확률분포로 부터 나왔는지에 대한 확률
- 고정되는 값은 확률분포  $D$ 가 아닌 관측값  $x$ 임
- 가능도 =  $L(\text{확률분포 } D \mid \text{관측값 } x)$




### ■ 최대 가능도 추정(Maximum Likelihood Estimation)

- 각 관측값  $x$ 에 대한 중 가능도(모든 가능도의 곱)이 최대가 되게하는 확률 분포
- 즉 모든 관측값들이 있을 수 있는 확률분포를 구하는 것
- MLE 시 먼저 임의의 확률분포를 가정해야 함

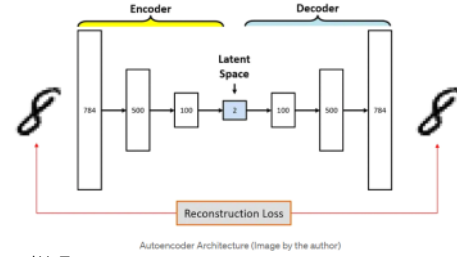
· 예를 들어 이러한 관측값이 존재할 경우, 이렇게 관측될 가능성이 가장 높은 확률분포를 찾는다 고 하면



- 이런식으로 중 가능도가 가장 높은 확률분포가 최대 가능도가 될 것이다.
- 또한 이 때 모든 관측값의 평균은 MLE를 통해 찾은 평균과 같다.



## 2. AE, AutoEncoder



### ■ 기본 구조


- 입력  $x$ 가 들어가면  $x$ 가 그대로 나오게 하는 것이 AE의 목적
- Encoder + Latent space + Decoder

- ★ 인코더에서는 입력레이어가 매우 작은 차원으로 포맷전환 되도록 함
- 이 과정에서 고차원의 데이터가 작은 데이터로 모델링됨 (차원 축소)

## 3. VAE, Variational Autoencoder

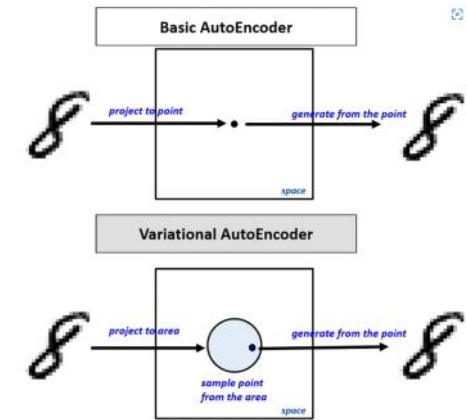
### ■ AE의 문제점

- a. 잠재공간의 해석이 어려움
- b. 잠재공간이 연속적이지 않음
- c. 생성된 데이터의 품질이 낮음




- > 위 그림은 MNIST를 학습한 AE의 잠재공간을 2D 산점도로 표현한 것
- > 보다 싶어 각 레이블이 even하게 균점화되지 않았고, 잘 scatter되지 않았음

### ■ VAE의 등장: 점에서 영역으로



Differences in latent space construction between an autoencoder and a variational autoencoder (image by the author)

- 기존의 AE는 인코더가 학습으로 배워낸 잠재공간이 개별 포인트로 고정됨(latent vector)
- (예를 들면, MNIST의 8을 인코더가 학습하면 디코더는 그 특정 포인트를 학습하는 것)
- VAE는 이 잠재공간을 사람이 해석하기 좋은 형태로 가정
- > 같은 숫자들의 데이터 포인트들은 같은 공간에 모여서 영역을 형성한다




### ■ 가우시안 분포를 사용하기

- 인간이 가장 해석하기 좋은 영역은 가우시안 분포(정규 분포)
- VAE는 가우시안 분포를 통해 잠재공간을 나누어 데이터 포인트들을 연속적 확률 분포로 나타냄

- a. 가우시안은 평균과 표준편차를 통해서 확률분포를 그릴 수 있음
- > 확률분포 그래프는 2차원 처럼 보이지만 실제로는 2차원이 아닌 1차원 데이터의 확률밀도함수(PDF)임
- > 1차원 PDF는 x축에 값, y축에 그 값의 확률 밀도를 나타냄

### ■ VAE의 예시 : MNIST

- a. 각 숫자 이미지에 대해서 인코더는 평균과 표준편차를 구하여 가우시안 분포를 생성
- b. 생성된 가우시안 분포는 잠재공간(2차원 가우시안 분포를 따름) 위에 매핑됨
- > 이 때의 분포는 너무 작아서 점 수준
- c. 각각의 이미지들의 분포가 잠재공간에 흩어져서 영역을 형성함
- > 비슷한 이미지들은 비슷한 위치에 모여서 영역을 이룰 것임
- d. 생성된 잠재영역에서 랜덤한 일부 부분을 샘플링 하면



어떻게 되는 것임

- e. 학습된 평균과 분산을 기반으로 하되, 그 분포 내에서 랜덤하게 샘플링

### ■ Log Variance 사용

$$\sigma = \exp(\log(\sigma)) = \exp\left(\frac{2\log(\sigma)}{2}\right)$$
$$= \exp\left(\frac{\log(\sigma^2)}{2}\right) = \exp(0.5 * \log\_variance)$$

### ■ VAE의 손실함

reconstruction error + KL Divergence

$$\mathcal{L}_{VAE}^{CE} = \mathcal{L}_{recon}^{CE} + \beta \mathcal{L}_{KL}$$

- 1) 재구성 오차
- 인코더의 입력과 디코더가 재구성한 데이터의 차이를 나타내는 손실함수
- MSE나 Binary Crossentropy 같은 거 사용

$$\mathcal{L}_{recon}^{CE} = -\mathbb{E}_{q_{\phi}(z|x)} [\log p_{\theta}(x|z)]$$

2) KL Divergence

$$KL \text{ Divergence} = D_{KL}[q(z|x)||p(z)]$$

- 하나의 확률분포  $q$ 가 다른 확률분포  $p$ 로 변하기 위해 필요한 양(측은 차이)
- $q(z)$ 를  $p(z)$ 로 맞추기 위해서 필요한 정보


- 인코더가 출력한 잠재변수의 분포 :  $q(z|x)$
- 표준 정규 분포 :  $p(z)$

- 즉 VAE의 잠재 공간이 표준정규분포로부터 얼마나 떨어져있는가를 나타내는 지표


b. 이를 2차원 영역으로 모델링 하려면 x축과 y축의 어느 점에 영역이 그려질지를 결정해야 함

- > 2차원 확률분포의 중심을 구하려면 x축의 평균과 y축의 평균이 모두 필요
- > 2차원 확률분포가 얼마나 퍼지는지를 구하려면 x축의 분산과 y축의 분산이 모두 필요
- >>> 즉 x\_평균, y\_평균, x\_표준편차, y\_표준편차 4개의 파라미터가 필요함

c. 위의 파라미터를 통해 그려진 2차원 확률분포의 그림은 다음과 같다



d. 2차원 잠재공간 위에 2개의 의미영역을 디자인




- > 잠재공간의 차원수와 모양을 특정하지 않기 때문에 그냥 M개의 정규분포를 이용하여 잠재공간을 디자인
- >VAE의 가장 큰 장점은 연속적인 잠재공간을 갖게 된다는 점

## ■가우시안 잠재공간과 샘플링

- AE에서는 Vector를 직접 연산해냄
- VAE는 확률분포를 결정하는 평균과 표준편차를 학습함

- 하지만 디코더는 확률분포가 아닌 의미가 있는 표현인 벡터가 있어야 디코딩이 가능함
- 확률 분포로부터 의미있는 벡터를 얻기 위해 **샘플링**을 수행



- 샘플링을 통해서 하나의 표현벡터를 얻어내고, 이 값이 디코더로 입력됨

### ※ 문제점

- 역전파 과정에서 샘플링 문제가 발생
- 샘플링 과정은 랜덤성이 포함되어 있어서 인코더 파트까지 역전파가 되지 않음
- >> 이를 해결하기 위해서 **재파라미터화 트릭**을 사용

## ■재파라미터화 트릭(Reparameterization Trick)

- 인코더와 디코더의 성능 향상을 위해서 VAE는 역전파가 필수적
- 역전파는 손실함수에 대한 각 매개변수의 기울기를 계산

- VAE에서 잠재변수 z는 인코더에서 얻은 평균과 표준편차를 바탕으로 무작위로 샘플링 됨
- $z = \mu + \sigma \cdot \epsilon$

(epsilon는 표준정규분포에서 샘플링된 값이며 무작위성을 가짐)

- >>> 이때 무작위성을 가지는 경우에는 평균과 표준편차의 변화에 따른 z값의 변화(가울기)를 알수가 없음, 즉 미분 불가능

- 재매개변수화 기법 : 인코더의 출력을 직접적으로 사용하여 z를 생성함
- >>> z를 생성할 때 사용된 평균과 표준편차의 변화가 어떤 영향을 미치는지 추적 가능